

Predicción de la Velocidad de Adopción de Mascotas

Análisis Exploratorio de Datos y Modelos Predictivos
sobre el Dataset PetFinder.my

Atencio, Malena Renée
MU: 0004

Orellana, Luz María
MU: 0030

Santellán, Andrea Paola
MU: 0018

Tecnicatura en Ciencias de Datos
Facultad de Ciencias Exactas y Naturales (FACEN)
Universidad Nacional de Catamarca (UNCa)
Cátedra: Laboratorio de Datos

June 30, 2026

Contents

1	Introducción	3
2	Descripción del Dataset	3
2.1	Variable objetivo	3
2.2	Diccionario de datos	4
2.3	Calidad de los datos	4
3	Análisis Exploratorio de Datos (EDA)	4
3.1	Estadísticas descriptivas	4
3.2	Distribución de variables categóricas	5
3.3	Análisis por grupo de variables	5
3.3.1	Variables descriptivas físicas (Atencio, M.)	5
3.3.2	Variables sanitarias y de cuidado (Orellana, L.)	5
3.3.3	Variables de edad, cantidad y costo (Santellán, A. P.)	5
4	Preprocesamiento y Selección de Variables	6
4.1	Transformaciones aplicadas	6
4.2	Matriz de correlación	6
5	Modelado Predictivo	6
5.1	Random Forest (parámetros iniciales)	6
5.2	Optimización de hiperparámetros (Grid Search manual)	7
5.3	Random Forest optimizado	7
5.4	Gradient Boosting + Grid Search	7
5.5	XGBoost + Grid Search	8
6	Comparación de Modelos	8
7	Conclusiones	9
8	Referencias	9

1. Introducción

El presente informe expone el trabajo final de la cátedra Laboratorio de Datos, correspondiente a la Tecnicatura en Ciencias de Datos de la UNCa, desarrollado en base al *dataset* **PetFinder.my**, publicado en la comunidad de ciencia de datos Kaggle por propuesta de la Prof. Lic. Cintia Sosa Chasampi.

PetFinder.my es el sitio de adopción de mascotas más utilizado de Malasia, donde refugios y particulares publican animales en adopción. El conjunto de datos contiene información mixta y heterogénea sobre cada mascota: características físicas, condición sanitaria, ubicación, fotografías y texto descriptivo.

El objetivo del trabajo es **predecir la velocidad de adopción** de una mascota (variable **AdoptionSpeed**) a partir de los atributos disponibles en el dataset, abordando el problema como una tarea de clasificación multiclase. Para ello se realizó un análisis exploratorio de datos (EDA) exhaustivo, seguido de un proceso de preprocesamiento y la aplicación de distintos modelos de aprendizaje automático: *Random Forest*, *Gradient Boosting* y *XGBoost*, optimizados mediante búsqueda de hiperparámetros (*Grid Search*).

2. Descripción del Dataset

El conjunto de datos original (**train.csv**) contiene **14.993 registros** y **24 variables**, con información sobre mascotas publicadas para adopción.

2.1. Variable objetivo

La variable a predecir, **AdoptionSpeed**, se categoriza en cinco clases:

Table 1: Categorías de la variable objetivo **AdoptionSpeed**

Valor	Significado
0	Adoptado el mismo día
1	Adoptado entre 1 y 7 días
2	Adoptado entre 8 y 30 días
3	Adoptado entre 31 y 90 días
4	No adoptado después de 100 días

2.2. Diccionario de datos

Table 2: Principales variables del dataset original

Variable	Tipo	Descripción
Type	Entero	Tipo de mascota (1 = Perro, 2 = Gato)
Name	Texto	Nombre de la mascota
Age	Entero	Edad en meses
Breed1 / Breed2	Entero	Raza principal / secundaria (0 = ninguna)
Gender	Entero	Sexo (1=Macho, 2=Hembra, 3=Mixto)
Color1/2/3	Entero	Colores de la mascota
MaturitySize	Entero	Tamaño adulto estimado
FurLength	Entero	Largo del pelaje
Vaccinated	Entero	Vacunado (1=Sí, 2=No, 3=No seguro)
Dewormed	Entero	Desparasitado (1=Sí, 2=No, 3=No seguro)
Sterilized	Entero	Esterilizado (1=Sí, 2=No, 3=No seguro)
Health	Entero	Estado de salud (1=Saludable, 2=Lesión menor, 3=Lesión grave)
Quantity	Entero	Cantidad de mascotas en la publicación
Fee	Entero	Costo de adopción
State	Entero	Estado/región de Malasia
PhotoAmt / VideoAmt	Decimal/Entero	Cantidad de fotos / videos
RescuerID / PetID	Texto	Identificadores
Description	Texto	Descripción de la mascota
AdoptionSpeed	Entero	Variable objetivo

2.3. Calidad de los datos

Se identificaron valores faltantes únicamente en dos variables:

- **Name:** 1.265 registros nulos ($\approx 8,4\%$).
- **Description:** 13 registros nulos ($\approx 0,09\%$).

Tratamiento aplicado:

- **Name:** al ser texto nominal sin valor predictivo directo (sin análisis de sentimiento), se transformó en una variable binaria (0 = sin nombre, 1 = con nombre), evitando así descartar filas.
- **Description:** dado el bajo porcentaje de nulos (13 registros), se optó por eliminar dichas filas, con impacto mínimo sobre el análisis.

3. Análisis Exploratorio de Datos (EDA)

3.1. Estadísticas descriptivas

- **Edad (Age):** media de 10,45 meses, mediana de 3 meses, lo que evidencia una fuerte concentración de animales jóvenes. El valor máximo (255 meses) indica presencia de posibles outliers.
- **Cantidad por publicación (Quantity):** la mayoría de las publicaciones corresponde a una sola mascota; existen casos de hasta 20 animales por publicación.
- **Costo de adopción (Fee):** media de 21,26, mediana de 0; la mayoría de las adopciones son gratuitas, con outliers de hasta 3000.
- **AdoptionSpeed:** media de 2,52, mediana de 2, concentrándose en tiempos intermedios de adopción.

3.2. Distribución de variables categóricas

- **Tipo de mascota:** predominan los perros (8.128 registros) sobre los gatos (6.852).
- **Sexo:** predominan las hembras (48,5%), seguidas por machos (36,9%) y mixto (14,5%).
- **Velocidad de adopción:** la categoría más frecuente es la clase 4 – no adoptado luego de 100 días – con 4.192 casos, seguida de la clase 2 (4.032), clase 3 (3.258), clase 1 (3.088) y clase 0 (410). Esto indica que una proporción importante de mascotas presenta tiempos prolongados de adopción.

3.3. Análisis por grupo de variables

El equipo dividió el análisis individual de variables en tres bloques de trabajo:

3.3.1 Variables descriptivas físicas (Atencio, M.)

- **Nombre:** no se observa una diferencia marcada en la velocidad de adopción entre mascotas con y sin nombre.
- **Tamaño y pelaje (MaturitySize, FurLength):** en todas las categorías predomina la clase 4 (no adoptado), lo que sugiere un dataset desbalanceado. El pelo corto domina entre las mascotas publicadas.
- **Raza pura vs. mezclada:** a pesar de existir mayor oferta de animales de raza pura, esto no garantiza una adopción más rápida.
- **Cantidad de colores:** no se observa relación clara entre el número de colores y la velocidad de adopción.

3.3.2 Variables sanitarias y de cuidado (Orellana, L.)

- **Vacunación y desparasitación:** las mascotas vacunadas/desparasitadas predominan en las categorías de adopción más rápidas (0, 1, 2), sugiriendo preferencia de los adoptantes por animales con atención sanitaria básica.
- **Estado de salud:** las mascotas saludables dominan las categorías de adopción rápida; las lesiones, especialmente graves, se asocian fuertemente con la clase 4 (no adoptado).
- **Esterilización:** también favorece adopciones más rápidas, aunque con un peso menor que la vacunación o la salud.

3.3.3 Variables de edad, cantidad y costo (Santellán, A. P.)

- **Edad vs. tipo:** tanto perros como gatos concentran la mayoría de observaciones en animales jóvenes, con numerosos outliers (especialmente en perros, superando los 250 meses). Para el análisis se filtró el rango de 0 a 18 meses sin alterar el dataset original. Dentro de este rango se observa una leve tendencia: a mayor edad, mayor velocidad de adopción (clases 3 y 4).
- **Cantidad de mascotas por publicación:** predominan ampliamente las publicaciones individuales; no se observa una relación clara entre la cantidad de animales publicados y la velocidad de adopción.
- **Costo de adopción:** la mayoría de las publicaciones presenta costo nulo o bajo, con mayor dispersión y outliers en perros respecto de gatos.

- **Estado/región (State):** se utilizó únicamente con fines exploratorios, sin incorporarse al modelo predictivo.

4. Preprocesamiento y Selección de Variables

A partir del análisis exploratorio, se decidió descartar las siguientes variables por bajo aporte predictivo o alto desbalance/dispersión:

Gender, Color1, Color2, Color3, VideoAmt, Description, PetID, RescuerID, PhotoAmt, MaturitySize, FurLength, Fee, State

4.1. Transformaciones aplicadas

- **Name:** binarizada (0 = sin nombre, 1 = con nombre).
- **Age:** categorizada en tres grupos según meses: Cachorro (0–12), Joven (12–60) y Adulto (60+).
- **Quantity:** categorizada en Individual (1), Grupo Pequeño (2–4) y Grupo Grande (5+).
- **Breed:** se generó una variable binaria **Breed** a partir de **Breed2** (1 = mestizo / tiene raza secundaria, 0 = raza pura), descartando **Breed1** y **Breed2**.

El dataset resultante (`dataset2`, exportado como `train_eda.csv`) quedó conformado por **14.980 registros y 10 columnas:** Type, Name, Age, Vaccinated, Dewormed, Sterilized, Health, Quantity, AdoptionSpeed, Breed, más las variables de tipo de mascota codificadas mediante *one-hot encoding* (Type_1, Type_2).

4.2. Matriz de correlación

Se calculó la matriz de correlación de Pearson sobre las variables numéricas resultantes, no observándose correlaciones fuertes entre los predictores, lo que descarta problemas relevantes de multicolinealidad para los modelos basados en árboles utilizados.

5. Modelado Predictivo

Para la etapa de modelado se utilizaron las siguientes variables predictoras:

Name, Age, Vaccinated, Sterilized, Health, Quantity, Breed, Type_1, Type_2

y como variable objetivo **AdoptionSpeed**, con división *train/test* de 80%/20% (estratificada en la mayoría de los casos para preservar la proporción de clases).

5.1. Random Forest (parámetros iniciales)

Se entrenó un primer modelo `RandomForestClassifier` con 700 árboles, profundidad máxima 5 y `min_samples_split=6`.

Table 3: Reporte de clasificación – Random Forest inicial

Clase	Precisión	Recall	F1-score	Soporte
0	0.00	0.00	0.00	82
1	0.14	0.00	0.00	618
2	0.30	0.65	0.41	806
3	0.40	0.00	0.01	652
4	0.40	0.59	0.48	838
Accuracy		0.34		

OOB Score: 0.3519.

Importancia de variables: Sterilized (0.355), Age (0.281) y Vaccinated (0.098) resultaron los predictores más influyentes.

5.2. Optimización de hiperparámetros (Grid Search manual)

Se realizó una búsqueda manual sobre las combinaciones de `n_estimators` $\in \{100, 500, 700\}$, `max_depth` $\in \{3, 5, 10\}$ y `min_samples_split` $\in \{2, 5, 6\}$, evaluando un total de 27 combinaciones.

Mejores hiperparámetros encontrados:

```
{'n_estimators': 100, 'max_depth': 5, 'min_samples_split': 6}
```

con un *accuracy* de validación de **0.3638**.

5.3. Random Forest optimizado

Reentrenando el modelo con los mejores hiperparámetros (manteniendo `oob_score=True` y estratificación en la partición):

Table 4: Reporte de clasificación – Random Forest optimizado

Clase	Precisión	Recall	F1-score	Soporte
0	0.00	0.00	0.00	82
1	0.32	0.02	0.04	618
2	0.30	0.65	0.41	806
3	0.40	0.00	0.01	652
4	0.41	0.58	0.48	838
Accuracy		0.34		

OOB Score: 0.3507. La mejora respecto del modelo inicial es marginal: aumenta la precisión en la clase 1, pero el *accuracy* global se mantiene prácticamente sin cambios.

5.4. Gradient Boosting + Grid Search

Se entrenó un `GradientBoostingClassifier` con búsqueda exhaustiva (`GridSearchCV`, `cv=5`) sobre 81 combinaciones de hiperparámetros (`n_estimators`, `learning_rate`, `max_depth`, `subsample`).

Mejores hiperparámetros: `{'learning_rate': 0.05, 'max_depth': 2, 'n_estimators': 100, 'subsample': 0.8}`, con *accuracy* de validación cruzada de **0.3469**.

Table 5: Reporte de clasificación – Gradient Boosting

Clase	Precisión	Recall	F1-score	Soporte
0	0.00	0.00	0.00	82
1	0.30	0.04	0.07	618
2	0.32	0.66	0.43	806
3	0.21	0.02	0.03	652
4	0.41	0.58	0.48	838
Accuracy en test		0.3501		

5.5. XGBoost + Grid Search

Finalmente se entrenó un `XGBClassifier` con búsqueda exhaustiva sobre 81 combinaciones (`n_estimators` $\in \{100, 200, 300\}$, `learning_rate` $\in \{0.05, 0.1, 0.3\}$, `max_depth` $\in \{3, 5, 7\}$, `subsample` $\in \{0.6, 0.8, 1.0\}$), con partición estratificada.

Mejores hiperparámetros: `{'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100, 'subsample': 1.0}`, con *accuracy* de validación cruzada de **0.3482**.

Table 6: Reporte de clasificación – XGBoost

Clase	Precisión	Recall	F1-score	Soporte
0	0.00	0.00	0.00	82
1	0.33	0.07	0.12	618
2	0.32	0.62	0.42	806
3	0.33	0.06	0.10	652
4	0.41	0.57	0.48	838
Accuracy en test		0.3548		

XGBoost obtuvo el mejor desempeño individual de *accuracy* en test entre los tres algoritmos evaluados, con mejoras notables en *recall* para las clases 1 y 3 respecto de Random Forest y Gradient Boosting.

6. Comparación de Modelos

Table 7: Comparación de *accuracy* entre modelos

Modelo	Accuracy CV/OOB	Accuracy Test
Random Forest (inicial)	0.3519 (OOB)	0.34
Random Forest (optimizado)	0.3507 (OOB)	0.34
Gradient Boosting	0.3469 (CV)	0.3501
XGBoost	0.3482 (CV)	0.3548

En los cuatro modelos se observa un patrón consistente: las clases **2** y **4** (adopción intermedia y no adopción) son las mejor predichas, mientras que la clase **0** (adopción inmediata) resulta prácticamente imposible de predecir correctamente con las variables disponibles, debido a su baja representación en el dataset (82 casos de 2.996 en test, apenas 2,7%).

La variable **Sterilized** (esterilización) y **Age** (edad) se mantienen consistentemente como los predictores más relevantes en los modelos basados en árboles.

7. Conclusiones

- El dataset PetFinder.my presenta un fuerte **desbalance de clases** en la variable objetivo, especialmente en la clase 0 (adopción inmediata), lo que limita el desempeño de los modelos evaluados, cuyo *accuracy* se ubica en torno al 34–35%.
- Las variables más influyentes para predecir la velocidad de adopción resultaron ser el **estado de esterilización** y la **edad** de la mascota, seguidas por el estado de vacunación.
- Variables como el color, el largo del pelaje o el tamaño adulto estimado no aportaron valor predictivo relevante y fueron descartadas del modelo final.
- Entre los algoritmos probados, **XGBoost** obtuvo el mejor *accuracy* en test (0.3548), superando a Random Forest y Gradient Boosting, aunque las diferencias entre modelos son moderadas.
- Como trabajo futuro, se considera necesario abordar el desbalance de clases (por ejemplo mediante técnicas de sobremuestreo u oversampling), e incorporar variables adicionales no utilizadas en esta etapa, como información textual de la descripción o la cantidad de fotografías, que podrían aportar señal predictiva adicional sobre el atractivo de la publicación.

8. Referencias

- PetFinder.my Adoption Prediction Dataset, Kaggle. <https://www.kaggle.com/c/petfinder-adoption-prediction>
- Documentación oficial de `scikit-learn`. <https://scikit-learn.org/>
- Documentación oficial de XGBoost. <https://xgboost.readthedocs.io/>